

O algoritmo Differential Evolution - DE

Profa. Érica C. R. Carvalho

2026

Evolução Diferencial

O algoritmo de **Evolução Diferencial**, ou *Differential Evolution* (DE), é uma metaheurística evolucionária proposta para resolver problemas de otimização, principalmente em espaços contínuos.


Ideia principal:

- ▶ Manter uma população de soluções candidatas;
- ▶ Gerar novas soluções a partir da diferença entre indivíduos;
- ▶ Comparar a nova solução com a solução atual;
- ▶ Preservar a melhor solução para a próxima geração.

Resumo:

DE usa diferenças vetoriais para guiar a busca.

Ideia geral do DE



DE x Algoritmo Genético

Característica	AG	DE
Representação	Binária ou real	Real
Operador principal	Crossover	Diferença vetorial
Mutação	Aleatória	Direcionada
Crossover	Combina pais	Combina vetor atual e mutante
Seleção	Populacional	Competição direta
Parâmetros principais	p_c e p_m	F e CR

Resumo:

- ▶ O AG explora combinações entre indivíduos;
- ▶ O DE explora diferenças entre indivíduos.

Passo 1 – População inicial

O algoritmo inicia com uma população de soluções candidatas.

Cada indivíduo é representado por um vetor de variáveis reais:

$$X_i = [x_1, x_2, \dots, x_D],$$

onde:

- ▶ i representa o indivíduo da população;
- ▶ D representa a dimensão do problema;
- ▶ cada posição do vetor representa uma variável de decisão.

Exemplo:

$$X_1 = [2.5, -1.0]$$

$$X_2 = [0.8, 3.2]$$

Passo 2 – Mutação diferencial

A mutação no DE utiliza a diferença entre indivíduos da população.

Para cada indivíduo alvo X_i , são escolhidos três indivíduos distintos da população:

$$X_{r1}, \quad X_{r2}, \quad X_{r3}.$$

O vetor mutante é calculado por:

$$V_i = X_{r1} + F \cdot (X_{r2} - X_{r3}),$$

onde:

- ▶ V_i é o vetor mutante;
- ▶ F é o fator de mutação;
- ▶ $(X_{r2} - X_{r3})$ define a direção da busca.

Intuição da mutação diferencial

A mutação diferencial cria uma nova solução usando a diferença entre dois indivíduos da população.

$$V_i = X_{r1} + F \cdot (X_{r2} - X_{r3}).$$

Interpretação:

- ▶ X_{r1} é o vetor base;
- ▶ $(X_{r2} - X_{r3})$ indica uma direção no espaço de busca;
- ▶ F controla o tamanho do passo nessa direção.

Ideia central:

A população fornece informações sobre para onde a busca deve ir.

Exemplo de mutação diferencial

Considere:

$$X_{r1} = [2, 4]$$

$$X_{r2} = [5, 8]$$

$$X_{r3} = [1, 3]$$

$$F = 0.5$$

Aplicando a equação:

$$V_i = X_{r1} + F(X_{r2} - X_{r3})$$

$$V_i = [2, 4] + 0.5([5, 8] - [1, 3])$$

$$V_i = [2, 4] + 0.5([4, 5])$$

$$V_i = [4, 6.5]$$

Passo 3 – Crossover

Após a mutação, o DE realiza o crossover entre:

- ▶ o vetor alvo X_i ;
- ▶ o vetor mutante V_i .

O objetivo é gerar um vetor candidato, chamado vetor teste:

$$U_i = [u_1, u_2, \dots, u_D]$$

O parâmetro CR controla a probabilidade de cada componente do vetor teste vir do vetor mutante.

$$CR \in [0, 1]$$

Ideia:

Combinar a solução atual com a solução mutante.

Exemplo de crossover

Considere o vetor alvo:

$$X_i = [2, 5, 1, 7]$$

e o vetor mutante:

$$V_i = [3, 4, 8, 6]$$

Após o crossover, um possível vetor teste seria:

$$U_i = [3, 5, 8, 7]$$

Interpretação:

- ▶ Algumas posições foram herdadas de V_i ;
- ▶ Outras posições permaneceram de X_i .

$$X_i = [2, 5, 1, 7]$$

$$V_i = [3, 4, 8, 6]$$

Passo 4 – Seleção

No DE, a seleção ocorre por competição direta entre:

- ▶ o vetor alvo X_i ;
- ▶ o vetor teste U_i .

Para um problema de minimização:

$$X_i^{novo} = \begin{cases} U_i, & \text{se } f(U_i) \leq f(X_i) \\ X_i, & \text{caso contrário} \end{cases}$$

Ideia principal:

- ▶ Se o vetor teste for melhor, ele substitui o vetor atual;
- ▶ Caso contrário, o vetor atual permanece na população.

Exemplo de seleção

Considere um problema de minimização.

Vetor alvo:

$$X_i = [2, 5]$$

$$f(X_i) = 29$$

Vetor teste:

$$U_i = [1, 3]$$

$$f(U_i) = 10$$


Como:

$$f(U_i) < f(X_i)$$

o vetor teste substitui o vetor alvo.

$$X_i^{novo} = U_i$$

Fluxograma do DE



Parâmetros do DE

Parâmetro	Função
NP	Tamanho da população
D	Dimensão do problema
F	Fator de mutação
CR	Taxa de crossover
gen	Número máximo de gerações

Valores comuns:

$$F \in [0.5, 0.9]$$

$$CR \in [0.7, 0.9]$$

Exemplo: minimização da função Sphere

Considere a função Sphere:

$$f(x_1, x_2) = x_1^2 + x_2^2$$

Objetivo:

$$\min f(x_1, x_2)$$

A solução ótima é:

$$x_1 = 0, \quad x_2 = 0$$

$$f(0, 0) = 0$$

No DE:

- ▶ cada indivíduo representa um vetor $[x_1, x_2]$;
- ▶ a qualidade do indivíduo é dada por $f(x_1, x_2)$;
- ▶ indivíduos com menor valor de f são melhores.

Exemplo simples de uma geração

Considere:

$$X_i = [2, 5]$$

$$X_{r1} = [1, 4]$$

$$X_{r2} = [5, 8]$$

$$X_{r3} = [3, 2]$$

$$F = 0.5$$

Mutação:

$$V_i = [1, 4] + 0.5([5, 8] - [3, 2])$$

$$V_i = [1, 4] + 0.5([2, 6])$$

$$V_i = [2, 7]$$

Continuação do exemplo

Vetor alvo:

$$X_i = [2, 5]$$

Vetor mutante:

$$V_i = [2, 7]$$

Após o crossover, suponha que o vetor teste seja:

$$U_i = [2, 7]$$

Avaliando na função Sphere:

$$f(X_i) = 2^2 + 5^2 = 29$$

$$f(U_i) = 2^2 + 7^2 = 53$$

Como:

$$f(U_i) > f(X_i)$$

o vetor alvo permanece na população.

Implementação

- ▶ Fazer uma implementação do DE para uma função teste sugerida.
- ▶ Testar outra função teste já utilizada anteriormente em outro algoritmo e comparar os resultados.

Parâmetros a testar:

- ▶ Tamanho da população NP ;
- ▶ Fator de mutação F ;
- ▶ Taxa de crossover CR ;
- ▶ Número de gerações gen .

Sugestões de funções de teste

► Sphere

$$f(x) = \sum_{i=1}^D x_i^2$$

► Rosenbrock

$$f(x) = \sum_{i=1}^{D-1} [100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2]$$

► Rastrigin

$$f(x) = 10D + \sum_{i=1}^D [x_i^2 - 10 \cos(2\pi x_i)]$$